CIÊNCIA DE DADOS

GUIA VISUAL

Revisão final para a prova

O essencial para reconhecer o enunciado, escrever o código e justificar a decisão de negócio.

FOCO

Modelo de cobrança

Cenário de negócio + código + interpretação.

REGRA

Não basta calcular

Explique o que o resultado permite concluir.

Revisão visual baseada nos slides, laboratórios e simulado integrador.

COMO A PROVA PENSA

O roteiro que se repete

O simulado TechMarket é a melhor previsão: a disciplina cobra uma análise de ponta a ponta.

ETAPA	PERGUNTA QUE O ENUNCIADO FAZ	ENTREGA ESPERADA
1. Proteger	Que dado expõe a pessoa sem ajudar o modelo?	Remover PII, justificar finalidade e minimização.
2. Diagnosticar	Como é a base? Há assimetria ou ruído?	describe(), moda, média x mediana, IQR.
3. Visualizar	Que gráfico traduz a pergunta?	Escolha pelo tipo da variável e interprete.
4. Comparar	A mudança A/B funcionou de verdade?	H0/H1, teste t, p-valor e decisão.
5. Relacionar	X e y caminham juntos?	Pearson/corr(), scatterplot; sem alegar causalidade.
6. Prever	Qual resultado para um novo X?	Regressão, R2, RMSE, previsão e faixa de erro.

MUITO ALTA

LGPD + PII

E-mail/CPF não são necessários para estimar gasto. Remova ou anonimiza.

MUITO ALTA

A/B e p-valor

Uma barra mais alta não é veredito. A regra é $p < 0.05$.

MUITO ALTA

Regressão

X precisa de duas dimensões: df[['Tempo']] e predict([[45]]).

Leitura segura de qualquer questão: o que o dado mede -> qual método cabe -> qual limite existe -> qual decisão pode ser tomada.

1. GOVERNANÇA E LGPD

Antes de analisar, reduza o risco

Em questões de cenário, o professor tende a cobrar a justificativa técnica e de negócio, não só o nome da lei.

PILAR	PERGUNTA	EXEMPLO DE CONTROLE
Confidencialidade	Quem pode ler?	IAM, permissões, criptografia.
Integridade	O dado foi alterado?	Hash, auditoria, rastreabilidade.
Disponibilidade	O dado está acessível quando precisa?	Backup, redundância, SLA.

FINALIDADE

Para que coletar?

O objetivo precisa ser explícito e legítimo.

ADEQUAÇÃO

O uso combina com o objetivo?

Não use o dado em propósito incompatível.

NECESSIDADE

Precisa mesmo guardar?

Colete e retenha somente o mínimo.

Resposta-modelo

“O modelo prevê gasto, não identidade civil. Portanto removo Email (PII) e preservo somente atributos necessários ao objetivo. A decisão reduz exposição e aplica o princípio da necessidade.”

```
df_seguro = df.drop(columns=['Email'])
```

PII: e-mail, CPF, nome, localização precisa. Sensíveis: saúde, biometria, raça, religião, política e orientação sexual.

2. ESTATÍSTICA DESCRITIVA

Diagnóstico: centro, dispersão e forma

Descritiva é a fotografia do passado. Ela organiza a base, mas não promete o futuro.

MEDIDA	O QUE DIZ	ALERTA DE PROVA
Média	Ponto de equilíbrio.	É puxada por valores extremos.
Mediana	Valor do meio da lista ordenada.	Resistente a outliers.
Moda	Valor/categoria mais frequente.	Serve para texto/categorias.
Variância	Dispersão ao quadrado.	Unidade é pouco intuitiva.
Desvio padrão	Oscilação na unidade original.	Alto = processo heterogêneo.

Assimetria em 3 segundos

SE VOCÊ VÊ	CONCLUSÃO
Média > mediana	Cauda à direita; extremos altos arrastam a média.
Média < mediana	Cauda à esquerda; extremos baixos arrastam a média.
Média ≈ mediana ≈ moda	Distribuição aproximadamente simétrica.

Quartis e a cerca de Tukey

Q1 = 25% | Q2 = mediana = 50% | Q3 = 75%
IQR = Q3 - Q1 LI = Q1 - 1.5 x IQR LS = Q3 + 1.5 x IQR
Ponto fora de LI/LS = outlier.

```
q1 = df['ticket'].quantile(0.25)
q3 = df['ticket'].quantile(0.75)
iqr = q3 - q1
df_limpo = df[(df['ticket'] >= q1 - 1.5 * iqr) &
              (df['ticket'] <= q3 + 1.5 * iqr)]
```

Pegadinha: em Series Pandas use & e parênteses; and não funciona.

3. VISUALIZAÇÃO

O gráfico é escolhido pela pergunta

A prova pode pedir o comando e a leitura visual. Escreva os dois.

OBJETIVO	VARIÁVEIS	GRÁFICO	LEITURA
Contar acessos	Categórica	countplot	Altura = frequência absoluta.
Comparar gasto médio	Categoria + número	barplot	Compara médias; note a variabilidade.
Ver evolução	Tempo + número	lineplot	Tendência e oscilações no tempo.
Ver distribuição	Número contínuo	histplot	Caudas, assimetria e concentração.
Encontrar outliers	Número / grupo + número	boxplot	Caixa = IQR; linha = mediana; pontos = outliers.
Relacionar números	Número + número	scatterplot	Direção, força, curvatura e ruído.
Ver muitas relações	Várias numéricas	heatmap	Relações lineares na matriz de correlação.

Atalhos de código

```
sns.countplot(data=df, x='Regiao')
sns.barplot(data=df, x='Regiao', y='Gasto_Site_R$')
sns.histplot(data=df, x='salario', bins=14, kde=True)
sns.boxplot(data=df, x='Versao_Site', y='Tempo_Tela_Min')
sns.scatterplot(data=df, x='Tempo_Tela_Min', y='Gasto_Site_R$', alpha=0.3)
sns.heatmap(df.corr(numeric_only=True), annot=True, cmap='coolwarm', fmt='.2f')
```

Sturges: k = 1 + 3.322 x log10(N). Para 8.065 registros, use aproximadamente 14 bins.

4. INFERÊNCIA E TESTE A/B

O visual sugere. O teste decide.

A diferença entre barras só é um indício. O p-valor testa se a evidência suporta a mudança.

H0 - HIPÓTESE NULA

Sem efeito real

As versões podem parecer diferentes por acaso ou ruído.

H1 - ALTERNATIVA

Há diferença

A mudança observada é estatisticamente significativa.

Régua de decisão

p < 0.05 -> rejeite H0: há evidência estatística de diferença.
p >= 0.05 -> falhe em rejeitar H0: a amostra não traz evidência suficiente para o deploy.

```
from scipy import stats

a = df[df['Versao_Site'] == 'A']['Tempo_Tela_Min']
b = df[df['Versao_Site'] == 'B']['Tempo_Tela_Min']
t_stat, p_valor = stats.ttest_ind(a, b)

if p_valor < 0.05:
    print('Rejeitamos H0: diferença significativa.')
else:
    print('Falhamos em rejeitar H0: não aprovar só por isso.')
```

NÃO CAIA NISSO	LEITURA CERTA
“p >= 0.05 prova que A e B são iguais.”	Não. Apenas falta evidência para afirmar diferença.
“B tem média maior, então venceu.”	Não sem testar variância, ruído e p-valor.
“Removo extremos para baixar o p.”	Limpe apenas com justificativa técnica/de negócio.

5. CORRELAÇÃO

Relação não é causalidade

A Teia de Aranha da disciplina: interpretar relação linear sem cair em conclusões de causa e efeito.

CONCEITO	LEITURA
Covariância	Mostra se variam juntas; depende da unidade/escala.
Pearson (r)	Relação linear padronizada de -1 a +1.
r > 0 / r < 0	Relação linear positiva / negativa.
r próximo de 0	Pouca relação linear; ainda pode existir relação curva.
Spearman	Usa ranking; útil em relação monotônica não linear.

O que dizer sobre o scatterplot

PADRÃO VISUAL	INTERPRETAÇÃO
Nuvem sobe / desce	Direção positiva / negativa.
Pontos colados numa reta	Associação linear mais forte.
Nuvem espalhada	Muito ruído; correlação/modelo menos confiável.
Curva clara	Pearson pode subestimar; considere Spearman.
Faixa horizontal/vertical	Possível teto, truncamento ou defeito de captura.

```
matriz = df.corr(numeric_only=True)
print(matriz['Preco'].sort_values(ascending=False))

r = df['Tempo_Tela_Min'].corr(
    df['Gasto_Site_R$'], method='pearson'
)
sns.scatterplot(data=df, x='Tempo_Tela_Min',
                y='Gasto_Site_R$', alpha=0.3)
```

Resposta que ganha ponto: “Há associação linear positiva moderada/forte. Isso não prova que X causa y; uma variável oculta pode explicar ambos.”

6. REGRESSÃO LINEAR

Do padrão à previsão

Correlação confirma relação; regressão constrói uma equação para estimar um novo valor.

EQUAÇÃO

y estimado = w0 + w1 x X

w1 é a inclinação; w0 é o valor previsto quando X = 0.

QUALIDADE

R2 e RMSE

R2 mede ajuste. RMSE é o erro típico na unidade de y.

FORMATO

X sempre 2D

Treino: df[['Tempo']]. Previsão: [[45]].

```
from sklearn.linear_model import LinearRegression
from sklearn.metrics import root_mean_squared_error, r2_score

X = df_modelo[['Tempo_Tela_Min']]  # 2D
y = df_modelo['Gasto_Site_R$']     # 1D

modelo = LinearRegression().fit(X, y)
y_pred = modelo.predict(X)

r2 = r2_score(y, y_pred)
rmse = root_mean_squared_error(y, y_pred)
peso = modelo.coef_[0]
vies = modelo.intercept_

previsao_45 = modelo.predict([[45]])[0]
piso, teto = previsao_45 - rmse, previsao_45 + rmse
```

SAÍDA	COMO TRADUZIR
coef_[0] = 25	Cada minuto adicional eleva a previsão de gasto em cerca de R$ 25.
intercept_ = 150	Com X = 0, o gasto base teórico estimado é R$ 150.
RMSE = 100	Uma previsão de R$ 900 deve ser comunicada aproximadamente como R$ 800 a R$ 1.000.
R2 alto	O modelo explica mais variação dos dados; não elimina erro e não prova causa.

ARSENAL DE CÓDIGO

Funções que resolvem cada etapa

A página para bater o olho antes de abrir o notebook: importe, calcule, filtre, mostre e decida.

BIBLIOTECA	IMPORT	PARA QUE SERVE
Pandas	import pandas as pd	DataFrame: ler, selecionar, filtrar, resumir e agrupar dados.
NumPy	import numpy as np	Vetores, números aleatórios, operações numéricas e simulações.
Seaborn	import seaborn as sns	Gráficos estatísticos rápidos: barras, caixa, histograma e dispersão.
Matplotlib	import matplotlib.pyplot as plt	Exibir, configurar título, eixo e tamanho dos gráficos.
SciPy	from scipy import stats	Teste t para comparar as duas amostras do A/B.
scikit-learn	LinearRegression, r2_score, root_mean_squared_error	Treinar regressão, medir ajuste e erro da previsão.

FUNÇÃO / PADRÃO	O QUE RESOLVE	EXEMPLO
describe()	Resumo numérico: contagem, média, desvio, min, quartis e max.	df['col'].describe()
mean() / median() / mode()[0]	Centro de dados numéricos / categoria mais frequente.	df['Regiao'].mode()[0]
quantile(0.25 / 0.75)	Q1 e Q3 para IQR e cercas de Tukey.	q1 = df['x'].quantile(.25)
drop(columns=[...])	Remove PII ou coluna inútil ao objetivo.	df.drop(columns=['Email'])
df[condição]	Filtro booleano: cria recorte ou base limpa.	df[(df.x >= li) & (df.x <= ls)]
groupby(...).describe()	Compara distribuições por grupo, como A e B.	df.groupby('versao')['ticket'].describe()
corr() / corr(method='...')	Matriz e coeficiente de correlação linear ou por ranking.	df['x'].corr(df['y'])

Cálculos e chamadas que mais caem

```
# Outliers (Tukey)
q1, q3 = df['x'].quantile(.25), df['x'].quantile(.75)
iqr = q3 - q1
li, ls = q1 - 1.5 * iqr, q3 + 1.5 * iqr

# Teste A/B
a = df[df['versao'] == 'A']['ticket']
b = df[df['versao'] == 'B']['ticket']
t, p = stats.ttest_ind(a, b)  # p < 0.05 -> rejeita H0

# Regressão e previsão (X 2D)
modelo = LinearRegression().fit(df[['Tempo']], df['Gasto'])
previsao = modelo.predict([[45]])[0]
```

Gráficos: `countplot` **conta;** `barplot` **compara média;** `histplot` **mostra distribuição;** `boxplot` **mostra IQR/outliers;** `scatterplot` **mostra relação;** `heatmap` **mostra a matriz de correlação.**

ESTATÍSTICA DESCRITIVA EM DETALHE

As fórmulas por trás do resumo

A função calcula em milissegundos; a prova quer saber se você entende o que cada número está dizendo.

MEDIDA	FÓRMULA	LEITURA
Média amostral	x barra = soma(xi) / n	Ponto de equilíbrio. Sensível a extremos.
Média populacional	mu = soma(xi) / N	Mesma ideia, agora para toda a população.
Variância amostral	s^2 = soma((xi - x barra)^2) / (n - 1)	Dispersão quadrática; n - 1 corrige subestimação.
Variância populacional	sigma^2 = soma((xi - mu)^2) / N	Dispersão de todos os elementos.
Desvio padrão	s = raiz(s^2)	Oscilação típica na unidade original: reais, minutos etc.

Exemplo manual

Base: [2, 4, 4, 4, 5]. Média = 19 / 5 = 3,8. Os desvios em relação à média são -1,8; 0,2; 0,2; 0,2; 1,2. Ao elevar ao quadrado, sinais negativos não se anulam. A variância populacional é 1,36 e o desvio padrão é aproximadamente 1,17.

SE O NÚMERO MUDA	O QUE PODE ESTAR ACONTECENDO
Média sobe muito; mediana quase não muda	Entrou outlier alto. A média foi arrastada.
Desvio padrão alto	Muita variação: processo instável ou grupos misturados.
Média e mediana muito próximas	Pode haver simetria; confirme no histograma.
Moda é texto	Normal: moda é a medida central adequada a categoria.

```
# Uma foto completa da coluna
resumo = df['salario'].describe()
media = df['salario'].mean()
mediana = df['salario'].median()
moda = df['Regiao'].mode()[0]
variancia = df['salario'].var()  # amostral por padrão
desvio = df['salario'].std()
```

QUARTIS E OUTLIERS

Do boxplot à limpeza justificável

Outlier é um alerta estatístico; antes de excluir, pergunte se ele é erro, fraude, evento raro válido ou segmento real.

Exemplo manual de quartis

Dados ordenados: [12, 15, 20, 30, 45, 60, 80]. Q2/mediana = 30. Metade inferior [12, 15, 20] -> Q1 = 15. Metade superior [45, 60, 80] -> Q3 = 60. Logo: IQR = 60 - 15 = 45.

CÁLCULO	RESULTADO	SIGNIFICADO
LI = Q1 - 1.5 x IQR	15 - 67,5 = -52,5	Abaixo disso: anomalia inferior.
LS = Q3 + 1.5 x IQR	60 + 67,5 = 127,5	Acima disso: anomalia superior.
Caixa do boxplot	Q1 até Q3	Os 50% centrais mais estáveis.
Linha da caixa	Q2	A mediana.
Bigodes e pontos	Dentro/fora das cercas	Extremos aceitáveis / outliers.

Como decidir o tratamento

SITUAÇÃO	AÇÃO MAIS DEFENSÁVEL
Valor impossível: idade = 500, preço negativo	Corrigir na origem ou remover; é erro de qualidade.
Fraude ou ataque detectado	Isolar e investigar; pode virar sinal do modelo de fraude.
CEO com salário muito alto	Não apagar automaticamente. Talvez seja dado real de outro segmento.
Teto de sistema (ex.: preço travado em 500 mil)	Documentar o truncamento; filtrar/ajustar antes da correlação/regressão.

```
# Identificar, contar e comparar antes/depois
q1 = df['salario'].quantile(.25)
q3 = df['salario'].quantile(.75)
iqr = q3 - q1
li, ls = q1 - 1.5 * iqr, q3 + 1.5 * iqr
mask_outlier = (df['salario'] < li) | (df['salario'] > ls)
print('outliers:', mask_outlier.sum())
df_limpo = df[~mask_outlier].copy()
sns.boxplot(data=df, y='salario')
```

PANDAS PARA INVESTIGAÇÃO

Faça perguntas antes de modelar

Muitos exercícios podem ser resolvidos combinando seleção, filtro, agregação e uma visualização correta.

OBJETIVO	PANDAS	EXEMPLO
Ver primeiras linhas	head()	df.head()
Ver tipos e nulos	info(), isna().sum()	df.info(); df.isna().sum()
Selecionar coluna	df['col']	df['Gasto_Site_R$']
Selecionar várias colunas	df[['a', 'b']]	X = df[['Tempo_Tela_Min']]
Filtrar linha	df[condição]	df[df['Regiao'] == 'Sul']
Contar categorias	value_counts()	df['Regiao'].value_counts()
Agrupar e resumir	groupby().agg()	df.groupby('Regiao')['Gasto'].mean()
Ordenar	sort_values()	df.sort_values('Gasto', ascending=False)

Pergunta -> operação -> visual

PERGUNTA	PRIMEIRO CÓDIGO	GRÁFICO
Qual região aparece mais?	value_counts() ou mode()[0]	countplot
Qual região gasta mais em média?	groupby('Regiao')['Gasto'].mean()	barplot
O gasto está muito espalhado?	describe(), quantile(), IQR	histplot + boxplot
A versão B alterou o tempo?	filtro A/B + ttest_ind	barplot + boxplot
Tempo e gasto se relacionam?	corr(), scatterplot	scatterplot + heatmap

```
# Leitura segura de uma base nova
print(df.shape)
print(df.dtypes)
print(df.isna().sum())
print(df.describe(include='all'))

# Uma pergunta de negócio
media_por_regiao = (df.groupby('Regiao')['Gasto_Site_R$']
                    .mean()
                    .sort_values(ascending=False))
print(media_por_regiao)
```

TESTE A/B EM DETALHE

Sinal, ruído e decisão

O teste t compara a diferença entre médias com o ruído interno das amostras. Diferença grande com variância enorme pode não ser convincente.

PASSO	O QUE ESCREVER NA RESPOSTA
1. Métrica	Defina y: ticket, tempo de tela, conversão etc. A e B devem medir a mesma métrica.
2. Hipóteses	H0: não há diferença real. H1: há diferença real.
3. Amostras	Filtre só os valores numéricos de A e B; não passe o DataFrame inteiro.
4. Teste	stats.ttest_ind(A, B) gera estatística t e p-valor.
5. Decisão	Com alfa = 0,05: se p < 0,05, rejeite H0; caso contrário, falhe em rejeitar H0.
6. Comunicação	Explique efeito, incerteza e limite: significância não mede impacto financeiro sozinha.

O que o p-valor realmente diz

Ele é a probabilidade de observar um resultado tão ou mais extremo assumindo que H0 seja verdadeira. Não é a probabilidade de H0 ser verdadeira, nem uma garantia de ganho. O atalho da prova continua: p < 0,05 -> rejeita H0.

CENÁRIO	DECISÃO
p = 0,003 e ganho prático relevante	Evidência forte; aprovar é plausível após validar custo/risco.
p = 0,13	Não há evidência suficiente; mantenha experimento ou não faça deploy por essa análise.
p = 0,001, mas ganho de R$ 0,01	Pode ser significativo e ainda irrelevante no negócio.
p = 0,04, dados desbalanceados/contaminados	Investigue qualidade e desenho do experimento antes de concluir.

```
# Verifique o contexto antes do veredito
resumo = df.groupby('versao')['ticket'].agg(['count', 'mean', 'median', 'std'])
print(resumo)

a = df.loc[df['versao'] == 'A', 'ticket']
b = df.loc[df['versao'] == 'B', 'ticket']
t, p = stats.ttest_ind(a, b)
print(f't={t:.3f}, p={p:.4f}')
sns.boxplot(data=df, x='versao', y='ticket')
```

CORRELAÇÃO COM OLHAR CRÍTICO

A matemática mostra padrão, não intenção

A correlação é ótima para priorizar investigação e escolher variáveis candidatas. Ela não substitui desenho experimental ou domínio do negócio.

TERMO	O QUE É	LIMITE
Covariância	Indica se duas variáveis sobem/descem juntas.	Depende de escala; não compare magnitudes entre unidades diferentes.
Pearson	Força e direção de uma relação linear, de -1 a +1.	Uma curva pode parecer fraca para Pearson.
Spearman	Correlação dos rankings; capta relação monotônica.	Também não prova causalidade.
Heatmap	Matriz visual de correlações entre variáveis numéricas.	Mostra associação, não um mecanismo de causa.

Checklist ao receber um r alto

PERGUNTA	POR QUE IMPORTA
A nuvem é aproximadamente uma reta?	Pearson mede relação linear; valide visualmente no scatterplot.
Há outliers ou teto artificial?	Poucos pontos podem distorcer r e a reta de regressão.
Existe fator escondido?	Calor pode explicar sorvete e ataques de tubarão; não é o sorvete causando ataque.
A variável faz sentido antes do resultado?	Domínio evita relações espúrias e decisões perigosas.
O dado permite ação causal?	Para afirmar causa, prefira experimento controlado ou estudo causal robusto.

```
# Pearson, Spearman, matriz e filtro de ruído
r_p = df['Renda_Bairro'].corr(df['Preco'], method='pearson')
r_s = df['Renda_Bairro'].corr(df['Preco'], method='spearman')
matriz = df.corr(numeric_only=True)
print(matriz['Preco'].sort_values(ascending=False))

df_limpo = df[df['Preco'] < 500000].copy()  # se o teto for defeito conhecido
r_limpo = df_limpo['Renda_Bairro'].corr(df_limpo['Preco'])
sns.heatmap(matriz, annot=True, cmap='coolwarm', fmt='.2f')
```

REGRESSÃO: PASSO A PASSO COMPLETO

Treinar é fácil; avaliar e explicar é o que vale ponto

A regressão linear simples tenta desenhar a reta que minimiza os erros quadráticos entre valores reais e previstos.

ETAPA	PERGUNTA	AÇÃO
Definir alvo	O que quero estimar?	y = gasto/preço/ticket.
Definir entrada	Qual X explica ou ajuda a prever y?	X = tempo/renda etc., sempre matriz 2D.
Higienizar	Há erro, teto ou outlier injustificado?	Filtrar com justificativa e documentar.
Treinar	Qual reta reduz o erro?	LinearRegression().fit(X, y).
Avaliar	A reta ajusta bem e erra quanto?	R2, RMSE e inspeção visual de resíduos.
Usar	Qual previsão para novo caso?	predict([[novo_x]]) e faixa com RMSE.

Métricas sem confusão

MÉTRICA	BOA LEITURA	NÃO DIGA
R2 = 0,70	O modelo explica 70% da variação observada de y naquele conjunto.	“O modelo está certo 70% das vezes.”
RMSE = R$ 100	Erro típico de cerca de R$ 100, na unidade real de dinheiro.	“Toda previsão erra exatamente R$ 100.”
coef = 25	Um minuto a mais aumenta a previsão em cerca de R$ 25, em média.	“Tempo causa R$ 25 a mais.”
intercept = 150	Previsão teórica quando X = 0.	“Todo usuário obrigatoriamente gasta R$ 150.”

```
# Pipeline inteiro
df_modelo = df[df['Gasto_Site_R$'] < 8000].copy()
X = df_modelo[['Tempo_Tela_Min']]
y = df_modelo['Gasto_Site_R$']

modelo = LinearRegression().fit(X, y)
y_pred = modelo.predict(X)
r2 = r2_score(y, y_pred)
rmse = root_mean_squared_error(y, y_pred)
novo = 45
base = modelo.predict([[novo]])[0]
print({'R2': r2, 'RMSE': rmse, 'previsao': base,
       'piso': base-rmse, 'teto': base+rmse})
```

SIMULADO INTEGRADOR

TechMarket - roteiro de resolução

Use como modelo mental se a prova trouxer uma base nova. A ideia é encadear análise, não decorar uma base específica.

FASE	MISSÃO	RESPOSTA/COMANDO
LGPD	Há e-mail dos clientes.	df_seguro = df.drop(columns=['Email']); justificar PII e minimização.
Diagnóstico	Qual região é mais frequente? Há outlier?	mode()[0], mean(), median(), describe(); comparar média x mediana.
Visual	Como provar para a diretoria?	barplot por região + boxplot do gasto.
A/B	Nova interface mudou tempo de tela?	filtrar A/B, ttest_ind, interpretar p contra 0,05.
Correlação	Tempo e gasto se relacionam?	corr() + scatterplot + ressalva de causalidade.
Previsão	Quanto gasta alguém com 45 minutos?	regressão, R2/RMSE, predict([[45]]) e faixa de erro.

Resposta de alto nível que conecta tudo

“Primeiro removi PII que não era necessária ao objetivo. Depois descrevi a distribuição e identifiquei valores extremos. Usei gráficos para comunicar os padrões. Para comparar A/B, testei H0 com teste t e p-valor. Para priorizar variável preditora, usei correlação e scatterplot sem afirmar causa. Por fim, treinei regressão e comuniquei previsão junto do RMSE.”

ERRO FREQUENTE	COMO EVITAR
Usar `and` em filtro Pandas	Use `&`, `|` e parênteses para cada condição.
Passar coluna 1D como X	Treine com `df[['Tempo']]`, não `df['Tempo']`.
Passar DataFrame inteiro ao teste t	Extraia duas Series numéricas: grupo A e grupo B.
Confundir p alto com igualdade	Escreva “falhamos em rejeitar H0”, não “provamos que são iguais”.
Confundir correlação com causa	Valide contexto, possíveis confundidores e desenho do estudo.

Se travar na prova, não pule direto para o código: escreva primeiro qual é o objetivo, qual variável é X, qual é y e qual decisão depende do resultado.

ÚLTIMA REVISÃO

Checklist e simulado relâmpago

Se você consegue responder a estes itens sem olhar, está muito bem posicionado para a prova.

PERGUNTA	RESPOSTA-CHAVE
Qual coluna tirar para prever gasto?	E-mail/CPF: PII não necessária ao objetivo -> drop/anonimizar.
Média 560 e mediana 535?	Assimetria à direita; outliers altos puxam a média.
Qual gráfico para contar dispositivos?	countplot. Para gasto médio por dispositivo, barplot.
p = 0.13 no A/B?	Falhar em rejeitar H0; não há evidência suficiente de diferença.
r = 0.69?	Associação linear positiva moderada/forte; não é causalidade.
Como prevê para 45?	modelo.predict([[45]])[0]; comunique RMSE como margem de erro.

MEMORIZE

Os 4 comandos

drop(columns=...), quantile(), filtro com &, ttest_ind().

MEMORIZE

As 3 regras

p < 0.05 rejeita H0; correlação não causa; X é 2D.

Roteiro de resposta de ouro

Finalidade -> diagnóstico -> visual -> limpeza justificada -> teste/relacionamento -> decisão.
Em qualquer interpretação, feche com uma frase de negócio e uma ressalva sobre qualidade/limites dos dados.

Boa prova. Respira, identifica o tipo de pergunta e segue o roteiro.